

DLIE-UprightNet 架构设计

Differentiable Lie-algebra Iterative Upright Estimator
状态：v0.3 (tangent-plane projection 已加入，待重新训练)

1. 设计目标

1.1 任务

从 $SO(3)$ 随机旋转后的点云 $P \in \mathbb{R}^{N \times 3}$ 估计其直立方向 $u \in S^2$ 。

1.2 基线与其缺陷

Pang 2022 (CVPR) 建立的 pipeline:



诊断得到的失败模式:


- 5.74% 样本 180° 翻转，集中在 lamp/bed/vase (灯罩 vs 灯底的支撑面歧义)
- 11pp test/train 准确率 gap: trunk 过拟合 1110 训练物体
- 不可微 → 无法端到端优化

1.3 核心创新

"Differentiable Lie-algebra Iterative Refinement"

1. RANSAC → 可微加权 SVD: 用 per-point 支撑概率加权协方差的最小特征向量作为粗初始化
2. Lie 代数迭代细化: 在 $so(3)$ 切空间做 coarse-to-fine 更新，用 exp map 保持 $SO(3)$ 正定
3. Tangent-plane projection: ΔR 限制在当前 up 的切空间 S^2 上，消除绕 up 轴的 gauge 自由度
4. Polarity feature 注入: 显式计算等变极性向量 $v_{polar} + skew_vec$ ，给 refine head 提供物体极性信号
5. 严格等变: 相对 frame 迭代机制保证 $f(gP) = g \cdot f(P)$ ($g \in SO(3)$)
6. 端到端可微: 梯度从最终 geodesic loss 回传至 trunk 的 support prediction

2. 整体数据流



3. 各组件详解

3.1 Trunk (预训练 + 可选微调)

UprightNetTrunk (来自 Pang 2022, 冻结或用 $lr=1e-5$ 微调)

```

P_t ∈ ℝ^{B×N×3} → transpose → (B, 3, N)
├── 3 × EdgeConv(k=20, ch: 3→32→64→128)
├── 4 × SelfAttention(ch=128) (stacked, cat → 512)
├── Conv1d(512 → 1024) + AdaptiveMaxPool1d → global_feat ∈ ℝ^{B×1024}
└── [x_a, x_b, x_c, global] → Conv1d → Conv1d → Conv1d → sigmoid
    │
    ▼
    sup ∈ [0,1]^{B×N}
    (per-point support prob)

```

输出: `global_feat (B, 1024)` + `sup (B, N)`, 二者共享同一前向的特征提取。

参数量: 2.22M (占模型 87%)。

3.2 Coarse Init (可微 SVD)

`weighted_plane_normal(P, w)` (Common/geometric_utils.py)

```

centroid = Σ w_i · p_i / Σ w_i
centered = p_i - centroid
Cov       = centered^T · diag(w) · centered / Σ w_i + ε · I
λ, V      = eigh(Cov)                                # ascending
normal    = V[:, :, 0]                                # smallest eigenvalue
sign      = sign(normal · (mass_center - support_center))
up_0      = sign · normal                            # ∈ S^2, SO(3)-equivariant

```

- **可微性:** `torch.linalg.eigh` 全程可微
- **等变性:** SVD 对 $SO(3)$ 严格等变
- **替代 RANSAC:** 所有点参与加权, `soft weights` 来自 `sigmoid` (不是硬阈值 `inlier`)

3.3 so3_from_up

从单个 `up` 向量 + 一个 `equivariant in-plane hint` 构造完整 $R \in SO(3)$:

```

hint' = hint - (hint·u)·u      # Gram-Schmidt 正交化
x      = normalize(hint')
z      = normalize(u × x)
x      = normalize(z × u)      # 保持 det(R) = +1
R      = [x | u | z] ∈ ℝ^{3×3} # R[:, :, 1] ≡ u

```

`hint = pca_largest_axis(P)` 保证整个构造严格等变。

3.4 Polarity Features

`PolarityFeatures(P_t, sup) → ℝ^6`

两个显式极性向量, 相对 `frame` 下都等变:

(a) 加权极性向量 `v_polar ∈ ℝ^3`

```

w          = sigmoid(sup).unsqueeze(-1)
w_norm     = w / Σw
v_polar    = Σ w_norm_i · (p_i - centroid)

```

物理意义：从支撑区域中心**指向物体整体方向**。对灯就是"从灯底指向灯罩"。

(b) 偏度向量 $\text{skew_vec} \in \mathbb{R}^3$

```
skew_vec = E[(p - centroid)3] / std3 # per-axis 3rd central moment
```

物理意义：沿各轴分布的不对称性，区分"底平顶尖" vs "顶平底尖"。

注意：两者都在 canonicalised P_t 坐标系下计算，所以在相对 frame 方案里都是 gauge-invariant 的标量/向量组合。

3.5 Refine Head

ContinuousRefineHead

```
fused (B, 1030) = concat[trunk_global (1024), polarity (6)]
|
| - Linear 1030 → 256
| - SiLU
| - Linear 256 → 256
| - SiLU
| - Linear 256 → 3 # raw ω^
|   (init: gain=0.01, bias=0)
ω_scaled = ω^ · tanh(||ω|| / θ_max) / ||ω|| # soft clip to θ_max
```

每次 iteration 传入不同 $\theta_{\max}$ (per-iter max angle)，实现 coarse-to-fine。

3.6 Tangent-plane Projection (本次关键修正)

Refine head 输出 $\omega^ \in \mathbb{R}^3$ 后**必须**投影到当前 up 的切平面：

```
u_t = R_t[:, :, 1]
ω = ω^ - (ω^ · u_t) · u_t
```

为什么：

任务 loss 只监督 $R[:, :, 1] = u_t$ ，绕 u_t 轴的旋转是 **gauge symmetry**——loss 梯度在该方向为 0。不投影时 refine head 可能学习"在无梯度方向乱转"（诊断中观察到 delta 25° 但 error 不变的现象）。

投影后：

- $\omega \perp u_t$ 严格成立（验证： $|\omega \cdot u| \max 4.47e-08$ ）
- 训练梯度信号强度 **6× 提升** (0.11 vs 0.017)
- $\exp_{so3}(\omega)$ 的一阶近似是 $u_{\{t+1\}} \approx u_t + \omega \times u_t$ ——标准 S^2 切空间更新

3.7 SO(3) Exponential Map (Rodrigues)

```
K = skew(ω) # 3×3 skew-symmetric from R^3
θ = ||ω||
exp_so3(ω) = I + (sinθ/θ) · K + ((1-cosθ)/θ^2) · K^2
```

严格可微，保 SO(3)。

4. 等变性声明

4.1 严格等变的部分

对任意 $g \in SO(3)$, 输入 gP 得到 $f(gP) = g \cdot f(P)$, 当且仅当:

1. **Coarse init:** `weighted_plane_normal`、`pca_largest_axis`、`so3_from_up` 都是严格等变 (SVD 经 `torch.linalg.eigh` 实现)
2. **Relative-frame iteration:** 第 t 步 trunk 的输入是 $R_t^T \cdot P$, 若 $R_t(gP) = g \cdot R_t(P)$ 则 trunk 输入不变
3. **Tangent projection:** 投影操作等变 (u_t 随 R_t 等变, $\hat{\omega}$ 在 trunk 不变输入下不变)
4. **exp_so3:** 元素级函数, 等变

4.2 近似等变

Trunk 本身不是结构等变, 但 Pang 2022 用 $100\times$ 随机旋转增广训练, 在实际数据上数值上 $\approx$ 等变。Exp 3 诊断显示:

- `trunk(P_rotated)`: support IoU 0.76 (训练分布)
- `trunk(P_canonical)`: 0.69
- `trunk(P_PCA_frame)`: 0.71

差距可接受。整体 pipeline 是 "near-equivariant"——对随机旋转的 test 数据能稳定工作。

5. 损失函数

5.1 多迭代 geodesic loss

$$L = \sum_{t=0..T} \gamma^{(T-t)} \cdot \arccos |(R_t[:, :, 1], u_{gt})|$$

- $\gamma=0.8, T=3 \rightarrow$ 权重 [0.512, 0.64, 0.8, 1.0]
- $t=0$ 项监督 coarse init 的可微 SVD 输出 $\rightarrow$ 让 trunk 的 support prediction 也被 upright loss 直接优化
- 后续项让 refine head 学到修正方向
- $|\cdot|$ 处理 antipodal 歧义: 物理上 up 和 -up 是同一个轴的两个方向

5.2 训练策略

阶段	参数	说明
当前	<code>lr_trunk=0, lr_head=1e-3</code>	冻结 trunk, 只训 refine head (验证架构)
下一步	<code>lr_trunk=1e-5, lr_head=1e-3</code>	解冻 trunk, 端到端微调 (主力实验)
消融	<code>trunk=random init</code>	回应审稿"为什么不从头训"

6. 超参数表

参数	值	说明
num_iters T	3	coarse + 3 次 refinement
max_angle_schedule	$[\pi, \pi/4, \pi/18] = [180^\circ, 45^\circ, 10^\circ]$	coarse-to-fine
trunk global dim	1024	UprightNet self-attn 后的 pool
polarity dim	6	v_polar (3) + skew_vec (3)
refine head hidden	256	2 层 SiLU MLP
γ (loss decay)	0.8	渐进权重
lr_head	1e-3	AdamW
lr_trunk	$0 \rightarrow 1e-5$	两阶段训练
batch size	48	RTX5880 48GB
num_points	2048	与 Pang 2022 一致
eps_cov (SVD 正则)	1e-5	防退化
grad clip	5.0	保护 eigh 梯度

7. 当前结果

模型	Mean	Median	Acc@10	Flip	备注
官方 Pang RANSAC	11.17°	0.71°	93.05%	5.72%	Phase 0 baseline
DLIE-Refine (zero-shot)	16.23°	0.80°	82.09%	6.12%	可微 SVD 版 Pang baseline
DLIE-Refine (1 epoch, no proj)	16.65°	0.83°	81.91%	6.38%	✗ refine 没学, gauge 乱转
DLIE-Refine (1 epoch, with proj)	TBD	TBD	TBD	TBD	🔬 进行中

7.1 Oracle 上限 (diag_ceilings.py)

- PCA frame oracle (T=0): 70.67% acc@10
- PCA frame + 3-step beam search (T=3): **100% acc@10**, mean 1.97°
- DLIE coarse init 起点 82%, refine oracle 上限理论上 > 100%

8. 关键文件

文件	内容
network_lie.py	所有李代数网络（含 4 个变体，推荐用 DifferentiableLieUprightRefineNet）
Common/geometric_utils.py	weighted_plane_normal 可微 SVD
scripts/train_dlie_refine.py	训练脚本
scripts/eval_dlie_refine_zeroshot.py	零样本评估
scripts/eval_official_baseline.py	Pang baseline 复现
scripts/diag_ceilings.py	4 个 oracle 诊断

9. 下一步

- 1. 重新训练（带 tangent projection）1 epoch，验证 refine 能降低 error
- 2. 如果 refine 真的 work：解冻 trunk，完整 5 epoch 训练
- 3. 消融：no-projection / no-polarity / T=1/2/3/4 / frozen vs unfrozen trunk
- 4. 泛化评测：UprightNet5（未见类别）、partial 扫描（ScanObjectNN）
- 5. 等变性数值验证：scripts/verify_equivariance.py 式的 test